Prédiction de la consommation d'énergie des bâtiments à Seattle

Seattle vise la neutralité carbone en 2050

Campagnes de mesure énergétiques coûteuses et ponctuelles

Besoin d'estimer la consommation des bâtiments non mesurés

Présenté par Ibrahima Embalo

Jeu de données initial

- Source : Seattle 2016 Building Energy Benchmarking
- 3 376 lignes, 46 variables
- Données hétérogènes : structure, usage, localisation, énergie, GES

Manquants et colonnes peu exploitables

Shape: (3376, 46)

	OSEBuildingID	DataYear	BuildingType	PrimaryPropertyType	PropertyName	Address	City	State	ZipCode	TaxParcelIdentificationNumber	...	Electricity
0	1	2016	NonResidential	Hotel	Mayflower park hotel	405 Olive way	Seattle	WA	98101.0	0659000030	...	1.15651
1	2	2016	NonResidential	Hotel	Paramount Hotel	724 Pine street	Seattle	WA	98101.0	0659000220	...	9.50425
2	3	2016	NonResidential	Hotel	5673-The Westin Seattle	1900 5th Avenue	Seattle	WA	98101.0	0659000475	...	1.45154
3	5	2016	NonResidential	Hotel	HOTEL MAX	620 STEWART ST	Seattle	WA	98101.0	0659000640	...	8.11525
4	8	2016	NonResidential	Hotel	WARWICK SEATTLE HOTEL (ID8)	401 LENORA ST	Seattle	WA	98121.0	0659000970	...	1.57344

Cadrage métier : focus non-résidentiel

```
...  BuildingType
     NonResidential          1460
     Multifamily LR (1-4)    1018
     Multifamily MR (5-9)     580
     Multifamily HR (10+)     110
     SPS-District K-12         98
     Nonresidential COS        85
     Campus                    24
     Nonresidential WA          1
     Name: count, dtype: int64
```

- Variable clé : BuildingType
- 8 types de bâtiments
- Filtre sur NonResidential uniquement
- 3 376 → 1 546 lignes

Target et filtrage de base

- Cibles candidates : colonnes énergie / GES
- Target retenue : SiteEnergyUse(kBtu)
- Drop NA sur la target : 1 546 → 1 544
- Filtre outliers 1–99 % : 1 544 → 1 512

```
...   TARGET: SiteEnergyUse(kBtu)

...   count    1.544000e+03
      mean     7.642371e+06
      std      1.865844e+07
      min      0.000000e+00
      25%      1.204670e+06
      50%      2.609590e+06
      75%      6.968646e+06
      max      2.930908e+08
```

Distribution de la consommation énergétique

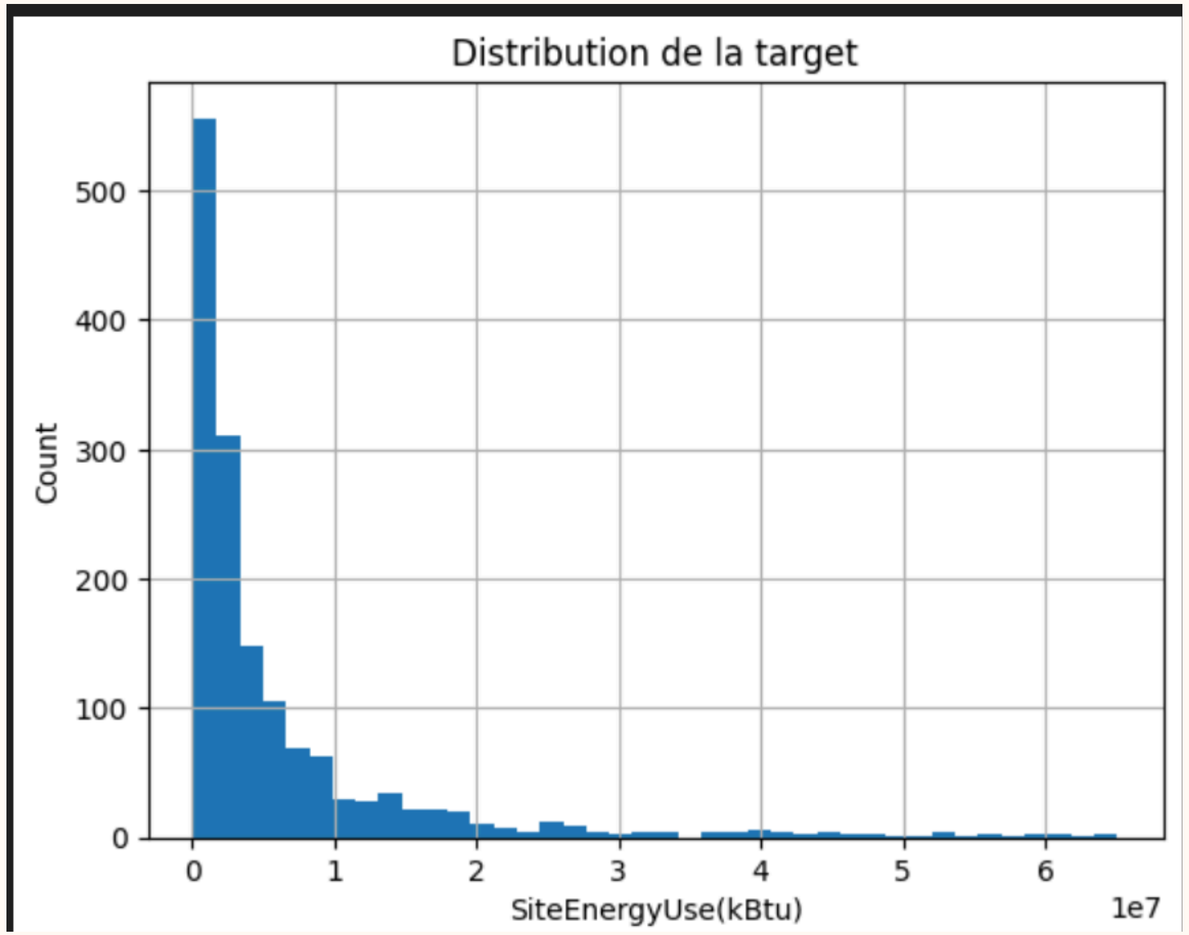

- Distribution très asymétrique
- Concentration sur des consommations faibles / moyennes
- Quelques gros consommateurs restant visibles

Surface et consommation

- Corrélation positive logique
- Forte dispersion pour les grandes surfaces
- Justifie la création de features dérivées

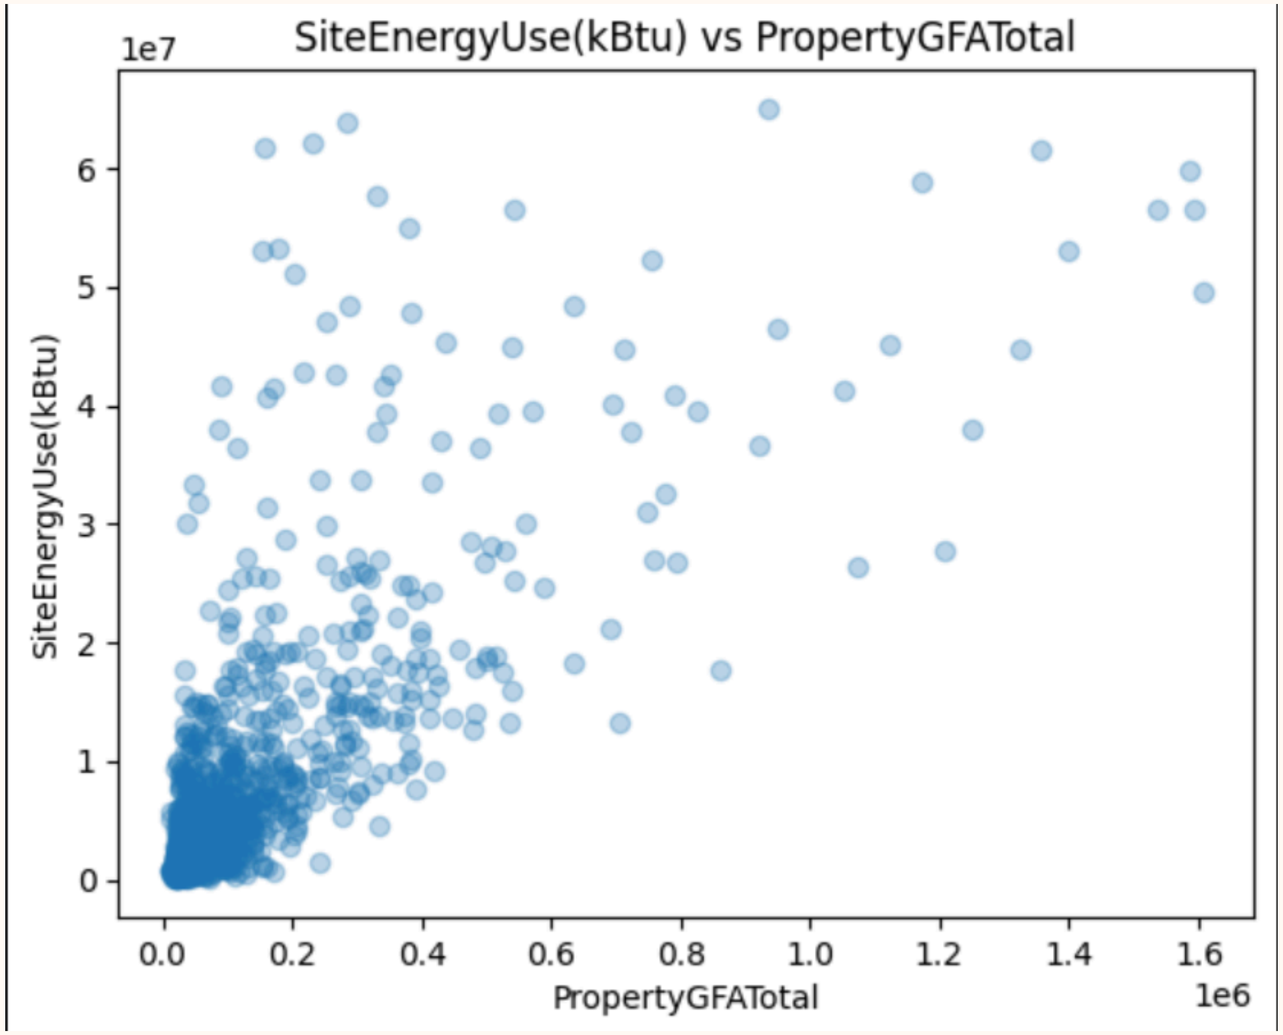

Impact du type de propriété

- **Forte hétérogénéité selon l'usage**
- **Hotels, grands bureaux, centres de distribution plus énergivores**
- **Confirme l'intérêt des variables d'usage**

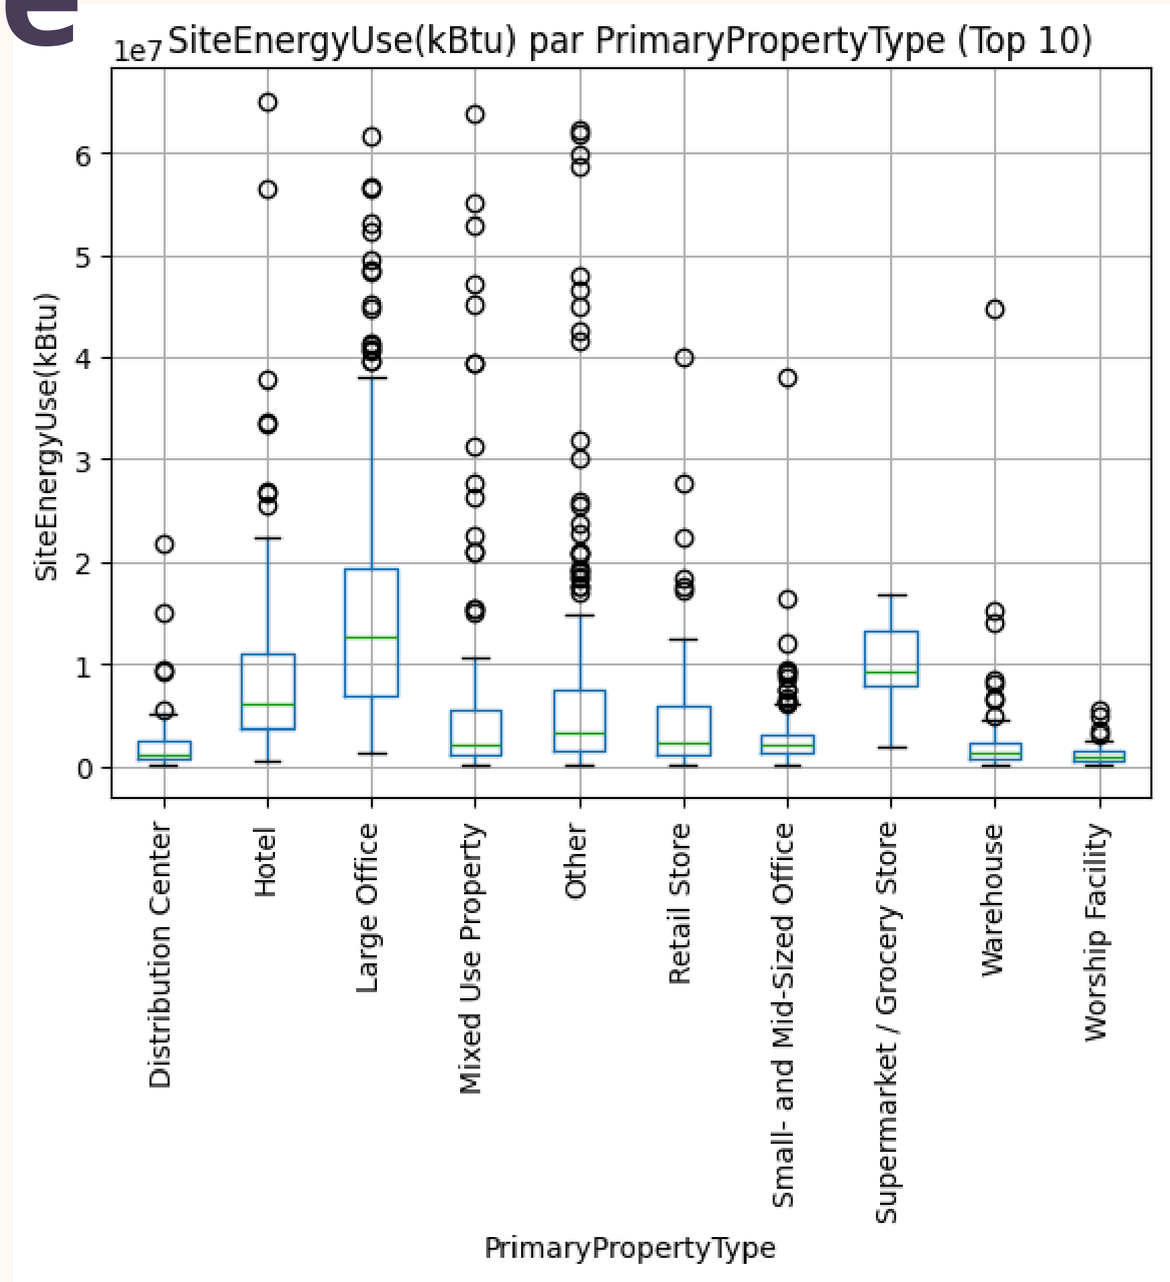

Feature engineering et fuites évitées

- **Nouveaux features créés :**
- **BuildingAge = 2016 - YearBuilt**
- **SurfaceBin (quantiles de surface)**
- **HasMultiUse (bâtiments multi-usages)**
- **Colonnes exclues (fuites) :**
- **IDs, adresse, ZIP…**
- **Toutes les mesures énergie / GES hors target**

Matrice de features finale

- Après filtrage :
- 1 512 lignes
- 28 features explicatives
- 15 numériques, 12 catégorielles, 1 booléenne
- Target unique : SiteEnergyUse(kBtu)

Pipeline de prétraitement

Schéma de la Pipeline :
ColumnTransformer → num (SimpleImputer + StandardScaler) / cat (SimpleImputer + OneHotEncoder) → RandomForest

Imputation médiane (num) / plus fréquente (cat)
Standardisation des numériques
OneHotEncoder avec handle_unknown="ignore"

Comparaison des modèles

	model	r2_mean	mae_mean
3	RandomForestRegressor	0.625559	2.963204e+06
4	GradientBoostingRegressor	0.630773	2.998921e+06
1	Ridge	0.621362	3.490361e+06
2	Lasso	0.604761	3.589741e+06
0	LinearRegression	0.590419	3.723300e+06

Modèle retenu et performance

- **Modèle final : RandomForestRegressor**
- **n_estimators = 400, max_depth = None, min_samples_split = 10**
- **Split 80 / 20 (train / test)**
- **R^2 test : 0,67**
- **MAE test : ~2,79 M kBtu**

Variables les plus influentes

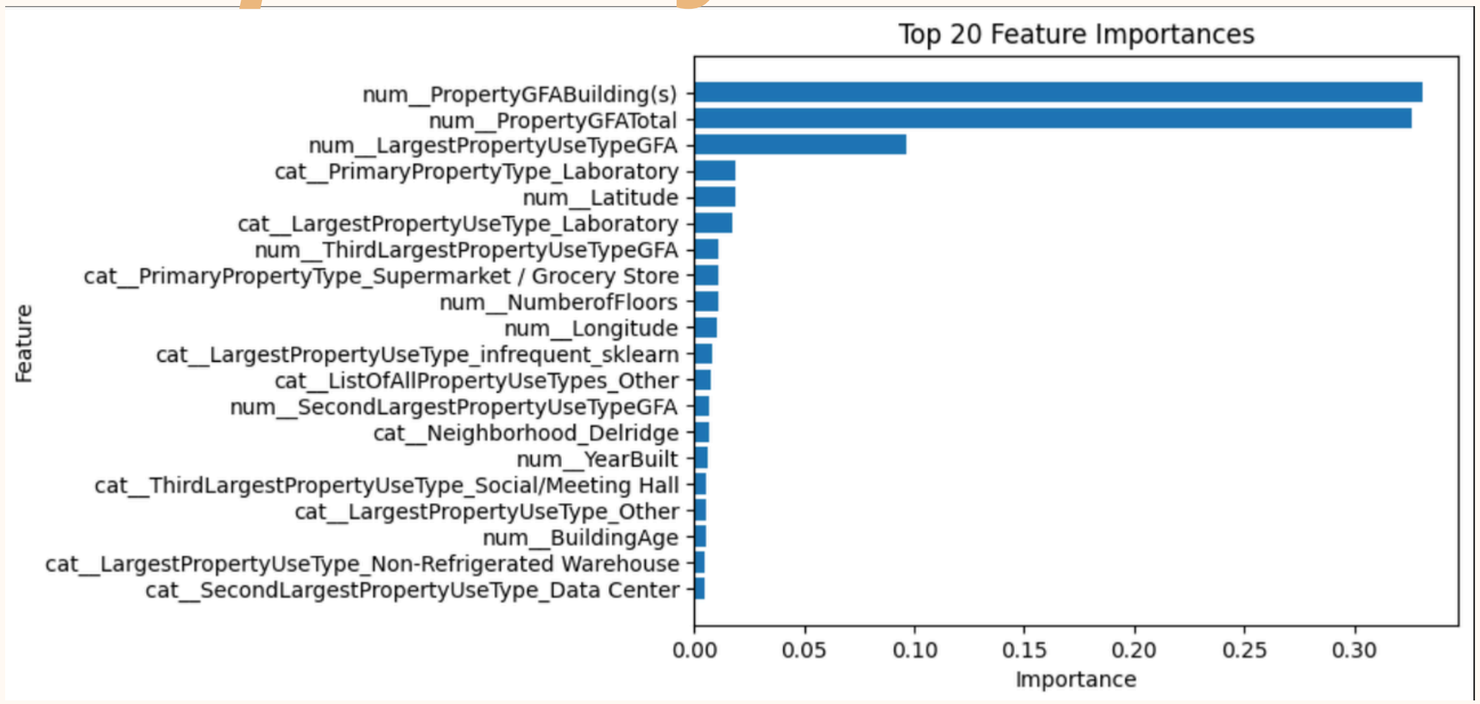

- **PropertyGFABuilding(s)**
- **PropertyGFATotal**
- **LargestPropertyUseTypeGFA**
- **Variables d’usage et de localisation dans le top 20**
- **Age / année de construction aussi présents**

Alignement strict features / modèle

- **OneHotEncoder peut supprimer des catégories**
- **Risque d’écart entre features “théoriques” et réelles**
- **Solution : récupérer les noms de features directement depuis le ColumnTransformer entraîné**

Limites du modèle

- **Distribution très asymétrique de la target**
- **Modèle entraîné sur 2016 uniquement**
- **Pas de variables climatiques ou d’intensité d’usage détaillée**
- **Pistes :**
- **transformation log, modèles gradient boosting avancés (XGBoost/LightGBM),**
- **focus sur sous-ensembles de typologies**

Exposition du modèle via une API BentoML

- **Modèle scikit-learn sauvegardé avec BentoML**
- **seattle_energy_model:vprfdsh466cucedf**
- **Service Bento : seattle_energy_service**
- **Endpoint principal : /predict (POST JSON)**
- **Validation d’entrée via Pydantic**

Endpoint et contrat d’entrée

- **Modèle Pydantic BuildingInput :**
- **property_gfa_total (float, > 0)**
- **largest_property_use_type_gfa**
- **number_of_floors**
- **year_built (1900–2016)**
- **primary_property_type (liste contrôlée)**
- **neighborhood, latitude, longitude, etc.**
- **Endpoint :**
- **POST /predict**
- **Input : BuildingInput**
- **Output : {"predicted_site_energy_use": float}**

Validation des données et erreurs

- **Pydantic bloque :**
- **surfaces négatives ou nulles**
- **dates hors bornes**
- **types de bâtiment inconnus**
- **Retourne des erreurs 422 structurées**
- **Empêche d’envoyer des requêtes incohérentes au modèle**

Test du service en local

- **Commande de lancement :**
- **bentoml serve service:svc**
- **Test via script test_client.py (requests)**
- **Exemple de réponse :**
- **Status 200**
- **{"predicted_site_energy_use": 2 811 057.32}**

Préparation du déploiement

- **bentofile.yaml contient :**
- **service : service:svc**
- **modèle : seattle_energy_model:***
- **code source api/service.py, api/test_client.py**
- **dépendances : scikit-learn, pandas, numpy, bentoml, pydantic…**
- **Image Docker construite via BentoML**
- **Publication de l’image dans un registry Cloud**
- **Déploiement sur service d’hébergement (ex: AWS / GCP / Azure / autre)**

Bilan

- **Modèle Random Forest $R^2 \approx 0{,}67$, MAE ≈ 2,8 M kBtu**
- **Basé uniquement sur des caractéristiques structurelles et d'usage**
- **API BentoML prête à être exposée aux citoyens**
- **Support pour la priorisation des rénovations et la planification énergétique**